

Ejercicio adicional

Para esta actividad adicional, se utiliza el stack de Airflow, Polars y Trino, se debe generar el pipeline con los siguientes requisitos:

1. Genera un nuevo DAG utilizando la información (dataset) disponible a tu elección en <https://ecobici.cdmx.gob.mx/en/open-data/>
2. El nombre del DAG se considera bajo tus criterios.
3. Genera una propuesta de limpieza de los datos seleccionados.
4. El DAG debe ejecutarse cada cierta cantidad de tiempo (5 min, 10 min, 30 min, etc)
5. Genera una propuesta de cómo guardar la información dentro del Bucket de Bronze, si se requiere una partición adicional, toda información debe guardarse en archivo parquet.
6. En cada ruta del parquet en Bronze, solo debe permanecer un solo parquet (Append)
7. Disponibilizar la información en Trino para visualizarse con DBeaver.

Preguntas:

¿Qué dataset se seleccionó para tu flujo?

¿Qué temporalidad se realizará la extracción? Explica por qué se seleccionó este timing.

¿Qué limpieza de datos usaste o crees que necesitaba los datos?

¿Qué propuesta de partición de ruta elegiste para el guardado de tu parquet y crees que esta partición afecta a Trino para su disponibilización automática de datos?

¿De todo el proceso, cuál fue el reto más grande? Explica el por qué