

Data Engineering Test

Motivación: Te agradecemos aceptar esta prueba como parte del proceso de reclutamiento para el puesto de ingenier@ de datos en GFB.

En promedio la gente sólo resuelve el 68% del examen. No te preocupes, nos interesa conocer tu forma de pensar, plantear problemas y resolverlos: ¡tu creatividad!

Cualquier duda sobre el test no dudes en preguntar vía email a Luis Angel Juarez ljuarez@bancobase.com, él estará gustoso de responderte.

Contenido de ejercicios

- 1. Para el primer ejercicio:** Generación de un pipeline en Airflow conectado a un lago de datos.
- 2. Para el segundo ejercicio:** la justificación de tu arquitectura como de tus respuestas a las preguntas debe entregarse en formato PDF. El texto puedes elaborarlo con cualquier software solo exportarlo en formato pdf y el diagrama de arquitectura incluyelo en formato SVG.

El challenge debe de enviarse en un correo electrónico mbarojas@bancobase.com y ljuarez@bancobase.com en la fecha que acordaste y debe de contener una URL a un repositorio en GitHub, GitLab o Bitbucket **público** con la siguiente estructura sugerida:

```
├── ejercicio1(folder)
│   ├── Airflow (folder)
│   ├── Minio(folder)
│   ├── docker-compose.yaml (archivo)
│   ├── readme.me
│   ├── data_prueba_tecnica.csv
│   └── <imagen>
├── ejercicio2(folder)
│   ├── diagrama (archivo SVG)
│   └── justificacion_de_tu_arquitectura.pdf
```

Ejercicio 1: Airflow + Trino

Se te proporciona el archivo ***data_prueba_tecnica.csv*** el cual contiene un *sample* del historial de transacciones de una compañía ficticia, lo encontrarás dentro de la carpeta ejercicio1.

Además contarás con un archivo `docker-compose.yaml` que habilita los siguientes servicios:

- Airflow, Minio, Trino

Supuestos:

- Los datos representan transacciones históricas de clientes.
- Los ids de los usuarios están enmascarados mediante un hash.

Objetivo:

Diseñar e implementar un proceso ETL que permita ingestar, procesar, limpiar y disponibilizar los datos para su consulta.

Se considerará un Plus si se usa Polars para todo el tema de procesamiento y manipulación de datos.

Instrucciones:

1. Estructura del Data Lake

Crea dos bucket dentro de Minio:

bck-landing y **bck-bronze**

2. Ingesta de datos

Carga el archivo *data_prueba_tecnica.csv* previamente creada dentro del bucket path: **bck-landing/data/data_prueba_tecnica.csv**

3. Generación de DAG

Genera un DAG llamado **etl_engineer_challenge** con los siguientes procesos:

3.1 Lectura de datos:

- Leer el archivo CSV que se cargó previamente en la ruta de minio.

3.2 Limpieza de datos, transformación y agregaciones

- Detecte y corrija inconsistencias en los datos
- Realizar agregaciones sobre los campos *name* y *created_at*.

3.3 Guardado del resultado

Guardar la información procesada en archivo parquet en la siguiente ruta de Minio:

- **path: bck-bronze/master/data_prueba_tecnica.parquet**

4. Trino

Generar el proceso necesario para habilitar la información del parquet guardado para ser consultado mediante Query SQL Trino.

4.1 Generar un task adicional al DAG existente para Trino

Generar el proceso necesario para habilitar la información del parquet guardado.

Instrucciones:

- Ya se tiene configurado el catálogo dentro de trino llamado: bronze
- Crear un schema dentro de bronze: prueba
- Crear una tabla dentro del schema bronze.prueba: tbl_data

Insumos para Trino:

<https://trino.io/docs/current/connector/hive.html#basic-usage-examples>

Para visualizar los datos generando query, se recomienda usar DBeaver para conectar con Trino:

<https://dbeaver.com/docs/dbeaver/Database-driver-Trino/#trino-specialty>

Preguntas adicionales:

Una vez terminado el ejercicio, responde a las siguientes preguntas dentro del archivo README de la carpeta ejercicio1:

1. Para los ids nulos ¿Qué sugieres hacer con ellos ?
2. Considerando las columnas name y company_id ¿Qué inconsistencias notas y como las mitigas?
3. Para el resto de los campos ¿Encuentras valores atípicos y de ser así cómo procedes?
4. ¿Qué mejoras propondrías a tu proceso ETL para siguientes versiones?
5. Guardar una captura de pantalla como imagen, de la query con Trino usando DBEaver

Ejercicio 2

Considera el siguiente escenario asumiendo el rol de ingeniero de datos:

El área operativa del departamento de TI tiene tres aplicaciones. Para cada aplicación su fuente de datos es de tipo transaccional y las tres funcionan 24/7. Llamemosles F1, F2 y F3 respectivamente, las cuales poseen las siguientes características:

- F1 es un CRM propietario. Contiene información sobre los clientes e.g. demográficos y datos de contacto.
- F2 tiene un RDBMS SQL Server. Almacena las transacciones de los clientes sobre la mitad de los productos que ofrece la compañía.
- F3 tiene un RDBMS Postgresql. Almacena las transacciones de los clientes sobre el resto de los productos.

Ten en cuenta los siguientes supuestos:

- Las tres fuentes de datos F1, F2 y F3 fueron diseñadas de manera independiente tanto a nivel de software como de modelo de datos.
- Como las fuentes de datos son operativas diariamente hay datos nuevos.

Tu objetivo es diseñar una arquitectura que consolide la información contenida en las fuentes de datos de F1, F2 y F3 que cumpla con dos propósitos: en primer lugar que habilite a un grupo de usuarios del área operativa a la extracción de consultas por medio de SQL y de manera secundaria que permita al equipo de ciencia de datos la aplicación de algoritmos de detección de patrones como clustering o búsquedas en grafos.

Tu diseño puede utilizar herramientas de almacenamiento y procesamiento diferentes para cada propósito si lo consideras necesario.

Instrucciones (ejercicio 2):

No olvides que las respuestas a las preguntas deben de argumentarse en el entregable:

- I. Propón una arquitectura (solo proponla no la construyas) que considere los siguientes aspectos y preguntas:
 - A. De cada fuente de datos se tienen identificados que campos requiere el área operativa. ¿Para cumplir con los dos objetivos que subconjunto de cada fuente de datos extraerías?
 - B. ¿Qué posibles retos implica la extracción de cada una de las fuentes de datos por separado y qué herramientas utilizas ?
 - C. ¿Qué posibles retos implica la independencia en el modelo de datos de las tres fuentes y cómo los resolverías?
 - D. ¿Aparte de un proceso batch en la hora de menor uso, cómo podrías mitigar el impacto de tu pipeline sobre las fuentes originales ?
 - E. ¿Cuáles etapas considerarías en tu proceso de transformación de datos y qué uso les darías?
 - F. ¿Qué herramientas utilizas para las etapas de transformación?
 - G. ¿Qué storage usarías para cada propósito y por qué ?
 - H. Recuerda que al menos a diario tendrás que llevar data nueva a tu etapa de transformación final, ¿Como orquestarias tu pipeline y con qué herramienta?
 - I. Proporciona un diagrama de tu propuesta de arquitectura.
- II. Seguridad (manteniendo tu rol de ingeniero de datos).
 - A. ¿Cómo mantendrías la seguridad de tu flujo de datos end-to-end? Es decir disminuir riesgos de posibles fugas o intrusiones no deseadas al entorno de ejecución que estás construyendo.
- III. Gobernanza de datos
 - A. ¿Cómo llevarías control de la metadata y sus cambios al igual que los procesos de tu pipeline y cómo almacenamos estos datos?

¡Buena suerte!

GFB Data Engineering Team.